

Типы муниципальных образований России по структуре безналичных расходов

Краткий методологический отчёт. Конкурс СберИндекса, направление «Кластеризация». Октябрь 2026.

Пути к файлам даны от корня репозитория проекта. Результаты в интерактивном виде: лендинг site/index.html.

1. Краткое содержание

Для 2004 муниципальных образований (МО) с полной историей за 24 месяца (январь 2023 – декабрь 2024) выделено шесть типов по структуре безналичных расходов: по долям продовольствия, здоровья, общепита, транспорта и маркетплейсов. Канонический метод: KMeans с $k = 6$ на z -оценках долей декабря 2024 года. Для сравнения построены экономическая сеть МО (kNN, $k = 8$, косинус z -оценок), разбиение Louvain, транспортные сети и семь альтернативных вариантов кластеризации.

Размеры типов: 411, 396, 334, 319, 111 и 433 МО. Внутренние индексы не показывают выраженной кластерной структуры (при $k = 6$: SW 0.226, CH/N 0.381, S_Dbw 1.182), gap statistic указывает $k = 3$ на почти плоской кривой. Типология остаётся интерпретируемой сегментацией; $k = 6$ выбран как компромисс, статистический критерий его не даёт. При независимой кластеризации каждого месяца 1625 из 2004 МО (81.1%) хотя бы раз меняют тип, медианный ARI соседних месяцев 0.569; тип описывает структуру расходов в конкретном месяце.

Из восьми методов по шести индексам Louvain получил лучший средний ранг (3.83 из 8; в одной из двух постановок его делит с KMeans на варианте B) за счёт сетевых индексов, которые он оптимизирует. KMeans $k = 6$ в середине (4.17 в общем пространстве признаков); единого победителя нет. Ближе всего к типам канонический kNN по косинусу z -оценок (ARI Louvain с KMeans 0.261), затем корреляция рядов (0.227); транспортные сети согласуются слабо (0.093 и 0.066). Высокое согласие канона частично возникает по построению (см. таблицу 1).

Конвейер из 62 записей выполняется за 31 мин 40 с; 343 из 356 созданных файлов совпали побайтно с рабочим каталогом, остальные 13 отличаются последними разрядами чисел или строкой со временем выполнения. Не реализованы пороговое агрегирование Алескерова, методы KEFRiN и CANUS, DTW; правило порога по косинусу сырых долей в сравнении правил (шаг 32) не вычислялось.

Схема метода: (1) Данные и отбор 2 004 МО, доли пяти категорий (шаги 01–03). (2) Z -оценки долей внутри месяца. (3) KMeans, $k = 6$, декабрь 2024: канонические типы. (4) Экономическая сеть kNN и Louvain; транспортные сети; сравнение правил ребра, методов и индексов. (5) Независимая кластеризация 24 месяцев и сопоставление с типами декабря 2024. (6) Проверки на внешних данных и описание типов. (7) Лендинг и воспроизводимый конвейер.

2. Данные и признаки

Основа: данные СберИндекса (лицензия CC BY-SA 4.0): потребительские безналичные расходы по категориям (303 126 строк, 2 190 МО, 24 месяца), индекс доступности рынков (2 571 МО, значения от 110.3 до 1 000.0) и автодорожные и железнодорожные расстояния между МО (5 942 364 строки: 3 303 736 highway и 2 638 628 railway). Данные Росстата (БД ПМО в обработке tochno.st, CC BY 4.0) используются только для проверки гипотез о готовых типах и в построении типов не участвуют.

Отбор (шаг 02): из 2 190 МО исключены 174 с историей короче 24 месяцев (остается 2 016) и 12 МО без значения индекса доступности рынков; итоговая выборка 2 004 МО. Доля категории равна значению категории, делённому на значение «Все категории» за тот же МО и месяц (48 096 строк долей). Пять долей в сумме дают в среднем 0.718 (от 0.458 до 0.905): пять категорий покрывают около 72% безналичных расходов, остальное («прочее») входит в канонический вариант признаков только неявно. Средние доли за весь период: продовольствие 0.439, здоровье 0.049, общепит 0.033, транспорт 0.058, маркетплейсы 0.139.

Каждая доля стандартизуется (z -оценка) по всем МО одного месяца. Без стандартизации косинусное сходство почти не различает МО: медиана сходства 0.9921 против 0.0087 после стандартизации (декабрь 2024).

Проверены три определения признаков: **A** (канон): пять долей от «Все категории»; **B**: те же доли, нормированные к сумме пяти; **C**: **A** и «прочее» как шестой признак. По внешним проверкам **A** и **C** равноценны, **B** ниже **A** по трём показателям (в том числе AMI с регионами, $p = 0.0014$; один из трёх не проходит поправку Бонферрони). Медианный ARI разбиений соседних месяцев **A** / **B** / **C**: 0.569 / 0.541 / 0.525. В внутренне компактнее (декабрь, $k = 6$: SW 0.248 против 0.226 у **A**, CH/N 0.474 против 0.381). Выбран вариант **A**.

Оговорки. Состав кластеров зависит от определения долей: при **B** ARI с канонем 0.40. При записи долей через лог-отношение к «прочему» разбиение слабо совпадает с канонем (ARI 0.277, 0.299 и 0.283 для трёх

кодировок), а доля «прочего» сама связана с типами ($\eta^2 = 0.57$). Типы остаются лишь одним из правдоподобных способов сегментации. Отдельного обоснования выбора именно пяти категорий и исключения индекса доступности рынков из признаков (он используется как атрибут узла) в репозитории нет.

3. Сеть и правило построения ребра

Канонический способ (шаги 05 и 06): z-оценки долей внутри месяца, попарный косинус, для каждого МО берутся 8 ближайших соседей, направленные рёбра объединяются, вес ребра равен сходству. Декабрь 2024: 2 004 узла, 10 425 рёбер (5 607 взаимных), плотность 0.0052, одна компонента, степень узла от 8 до 19 (медиана 10). Граф строится независимо для каждого из 24 месяцев: рёбер от 10 314 до 10 498; доля общих рёбер (Жаккар) в соседних месяцах 0.135–0.209 (среднее 0.184), между январём 2023 и декабрём 2024 0.063. Для сравнения, Жаккар одноимённых кластеров KMeans в соседних месяцах 0.634 (см. таблицу 4).

Отклонённый вариант: порог по косинусу сырых долей (шаг 04, порог 0.9) даёт 2 002 208 рёбер из 2 007 006 пар (99.8%), плотность 0.9976: сеть не различает МО. Транспортные сети строятся по расстояниям, статически: highway kNN8 имеет 9 986 рёбер (6 046 взаимных, 2 компоненты из 1 986 и 18 узлов); railway kNN8 имеет 6 402 ребра (3 678 взаимных) на 1 260 МО, 744 МО вне железнодорожной сети; 100 отсутствующих железнодорожных пар достроены нулевым расстоянием. Из 10 425 рёбер экономической сети 611 совпадают с рёбрами highway (при случайном совпадении ожидалось 51.9) и 308 с рёбрами railway. Индекс доступности рынков в сеть не входит и хранится как атрибут узла.

Сравнены пять правил: R1 (канон), R3 (корреляция месячных рядов за 24 месяца), R4 (лаговая корреляция, лаги от -2 до +2 месяцев), R5 (highway), R6 (railway). На каждом графе запущен Louvain (resolution 1.0, seed 42) и измерено согласие с каноническими типами KMeans.

Показатель	R1 канон	R3 корр. рядов	R4 лаговая корр.	R5 highway	R6 railway (1 260 МО)
Рёбер	10 425	12 393	12 952	9 986	6 402
Доля взаимных рёбер	0.538	0.294	0.238	0.605	0.575
Ассортативность по типам	0.742	0.633	0.321	0.373	0.289
Доля рёбер внутри типа	0.789	0.700	0.447	0.488	0.425
K Louvain	16	16	9	30	24
ARI с KMeans	0.261	0.227	0.107	0.093	0.066
NMI с KMeans	0.479	0.413	0.193	0.250	0.200
SW разбиения Louvain	0.081	0.033	-0.066	-0.110	-0.121

Таблица 1. Правила построения ребра, декабрь 2024. R1, R3–R5: 2 004 МО; R6: 1 260 МО с железнодорожной сетью. kNN, k = 8 для всех правил; вес ребра: R1 сходство, R3 и R4 корреляция, R5 и R6 равен 1. Источник: notebooks/32_edge_rules.md.

R1 согласуется с типами сильнее остальных, но частично по построению: рёбра R1 и типы KMeans получены в одном пространстве признаков. Низкое согласие R3 и R4, основанных на временных рядах, не значит, что эти правила хуже. R4: у 59.3% рёбер лучший лаг равен нулю, лаговая информация добавляет мало.

На общем пересечении 1 260 МО значения снижаются, порядок R1 > R3 > R4 сохраняется (ARI с KMeans: R1 0.244, R3 0.201, R4 0.083, R6 0.066, R5 0.066). 744 МО вне сети R6 распределены по типам 0–5 как 130, 90, 125, 161, 51 и 187. Замена веса ребра на единицу меняет K у R1 с 16 до 17, у R3 с 16 до 14, у R4 с 9 до 10; ARI с KMeans у R1 0.261 → 0.257, у R3 0.227 → 0.247, у R4 0.107 без изменений.

Индексы MQ, AVI и AVU посчитаны на собственном графе каждого правила и между правилами не сопоставимы; в таблицу они не вынесены. Число соседей: при k = 5, 8, 12 Louvain даёт K = 22, 16, 13, ARI с каноном 0.235, 0.286, 0.297, ARI между разбиениями 0.42–0.64. Значение k = 8 отдельно не обосновано; проверка показывает, что Louvain чувствителен к числу соседей.

Правила построения рёбер: структура сети и результаты Louvain (декабрь 2024)




Рисунок 1. Правила построения рёбер: структура сети и результаты Louvain (notebooks/figures/32_edge_rules.png).

4. Кластеризация и динамика типов

k	SW	CH	CH/N	S_Dbw	S_Dbw norm	PS
4	0.230	919.4	0.459	1.269	-8.541	0.481
6	0.226	763.9	0.381	1.182	-6.845	0.513
7	0.223	705.0	0.352	0.959	-7.164	0.340
8	0.210	665.5	0.332	0.957	-6.654	0.330

Таблица 2. KMeans, 5 z-оценок долей, декабрь 2024, 2 004 MO. PS: prediction strength. Источник: notebooks/10c_final_clustering_k6.md.

SW и CH максимальны при k = 2 (SW 0.407, CH 1 441) и убывают с ростом k; prediction strength проходит пороги 0.8 и 0.9 только при k = 2 и 3; gap statistic выбирает k = 3, кривая почти плоская (размах 0.041 при s_k около 0.009); доверительные интервалы S_Dbw norm для k = 6, 7, 8 перекрываются. Связь с внешними показателями (регионы, индекс доступности рынков, рёбра highway) растёт с k. Значение k = 6 выбрано как компромисс между устойчивостью и связью с внешними данными; критерий его не определяет. До 28.09.2026 каноном был k = 7; он заменён на k = 6 по prediction strength и воспроизводимости транспортной группы. Слабое место k = 6: тип 4 «Удалённые территории» (111 MO) наименее воспроизводима (PS 0.62, во времени 15 из 23 месяцев). Внутри месяца запуски у минимума inertia дают варианты одной структуры (медианный ARI 0.966, минимальный 0.920).

Тип	МО	Имя (интерпретационное)	Технический профиль
0	411	Посылка без транспорта	транспорт ниже, маркетплейсы выше, общепит ниже среднего (общепит на границе порога)
1	396	Средний по размеру	без выраженного профиля; МО в среднем крупнее среднего МО выборки
2	334	Маркетплейсы и здоровье	маркетплейсы выше, общепит ниже, здоровье выше среднего (здоровье на границе порога)
3	319	Столицы и крупные города	общепит выше, продовольствие ниже, маркетплейсы ниже среднего; около 72% типа составляют внутригородские МО Москвы и Санкт-Петербурга
4	111	Удалённые территории	маркетплейсы ниже, здоровье ниже среднего; низкая доступность рынков
5	433	Домашний стол	продовольствие выше, общепит ниже среднего (общепит на границе порога)

Таблица 3. Типы декабря 2024. Признак входит в техническое имя, если отклонение доли от среднего по выборке не меньше 0.5 стандартного отклонения и по доле, и по логарифму отношения доли к «прочему», с одним знаком; пометка «на границе порога» означает запас 0.1σ. Источники: notebooks/23_type_portraits.md, docs/type_names.md.

KMeans запускается независимо на каждый месяц (100 запусков, официальное разбиение с минимальной inertia). Кластеры месяца сопоставляются с каноническими типами декабря 2024 венгерским алгоритмом по евклидову расстоянию между центроидами в пространстве z-оценок, напрямую с якорем, без цепочки по соседним месяцам. Сопоставление в исходных долях отклонено: тренд сдвига долей маркетплейсов

(+0.099) делает его неустойчивым. Уверенность пары оценивается отношением расстояния до ближайшего конкурента к расстоянию до сопоставленного центра.

Показатель (k = 6)	Значение
ARI разбиений соседних месяцев, медиана	0.569
Жаккар одноимённых кластеров соседних месяцев, среднее	0.634
МО, хотя бы раз менявшие тип за 24 месяца	1 625 из 2 004 (81.1%)
МО, ни разу не менявшие тип	379 (18.9%)
Среднее число смен на МО (23 перехода)	5.36 (медиана 5, максимум 18)
Чистая миграция (мода первых 6 месяцев ≠ мода последних 6)	511 МО (25.5%)
Одномесечные переходы среди всех переходов в новый тип	1 689 из 2 808 (60%)
Уверенность принадлежности (доля из 100 запусков в том же кластере)	медиана 1.00; не менее 0.7 в 96.4% МО-месяцев
Проблемные месяцы	1 (2023-02)
ARI декабря 2023 и декабря 2024 по общим МО	0.515
Доля МО типа в декабре 2024, остающихся в нём не менее 90% месяцев	тип 3: 90.6%; тип 1: 36.6%; тип 2: 35.9%; тип 0: 26.3%; тип 5: 21.2%; тип 4: 4.5%

Таблица 4. Устойчивость типов во времени. Источники: notebooks/12_kmeans_temporal_tracking_k6.md, docs/interpretation.md.

Почти все МО меняют тип хотя бы раз (81.1%), и 60% переходов длятся один месяц. Это согласуется со слабой кластерной структурой (см. таблицу 2): МО у границ типов переходят между соседними типами от месяца к месяцу. Устойчивее всего тип 3 (крупные города), наименее устойчив тип 4.

Из 2 594 МО в слое карты тип напрямую получен у 2 004. Для 98 МО из набора расходов, не вошедших в выборку, тип присвоен по ближайшему центроиду канонического разбиения (расстояние не больше максимума по выборке; у 45 из 98 оно больше 95-го перцентиля расстояний выборки). Для 74 МО без данных за декабрь 2024 тип присвоен по последнему месяцу с полными пятью категориями. У 418 МО типа нет. Присвоенные типы не входят в статистики проверок.

5. Сравнение методов и индексы качества

Сравнены восемь методов на декабре 2024 (2 004 МО) по шести индексам: M1 KMeans (вариант признаков A, k = 6); M2 KMeans (A, k = 17, как у Louvain); M3 KMeans на варианте B; M4 KMeans на варианте C; M5 иерархический метод Уорда (A); M6 гауссова смесь (A); M7 спектральная кластеризация по канонической сети; M8 Louvain по канонической сети (итоговый запуск, 100 запусков, лучший по MQ, K = 17).

Метод	K	SW ↑	CH ↑	S_Dbw ↓	MQ ↑	AVI ↑	AVU ↓	Средний ранг (общее A / собств.)
M1 KMeans, A	6	0.226	763.9	1.182	0.608	0.774	0.593	4.17 / 4.50
M2 KMeans, A, k = K Louvain	17	0.188	470.9	0.588	0.579	0.615	0.493	4.33 / 4.50
M3 KMeans, B	6	0.184	676.4	0.872	0.567	0.728	0.565	4.83 / 3.83
M4 KMeans, C	6	0.210	713.8	1.129	0.587	0.759	0.567	4.33 / 4.50
M5 Ward, A	6	0.187	649.2	1.133	0.604	0.776	0.545	4.17 / 4.33
M6 Гауссова смесь, A	6	0.141	494.7	1.009	0.538	0.707	0.552	6.00 / 6.00
M7 Спектральная, сеть	6	0.153	637.9	1.079	0.728	0.903	0.586	4.33 / 4.50
M8 Louvain, сеть	17	0.111	338.1	0.598	0.787	0.842	0.519	3.83 / 3.83

Таблица 5. Метод × шесть индексов, декабрь 2024. SW, CH, S_Dbw: в общем пространстве признаков A для всех методов; MQ, AVI, AVU: на одной канонической сети. Стрелки: ↑ больше лучше, ↓ меньше лучше. Последний столбец: средний ранг по шести индексам в общем пространстве A и в собственном пространстве метода. В собственном пространстве у M3 SW 0.246, CH 951.3, S_Dbw 0.879; у M4 SW 0.222, CH 759.0, S_Dbw 1.056. Источник: notebooks/31_method_comparison.md.

Louvain (M8) имеет лучший или равный лучшему средний ранг в обеих постановках (3.83; в собственном пространстве его делит M3): он первый по MQ, который оптимизирует прямо, и последний по SW и CH. Вариант M2 (KMeans с тем же числом групп) лучший по S_Dbw и AVU.

Положение M3 зависит от пространства: средний ранг 3.83 в собственном пространстве и 4.83 в общем. Канон M1 стоит в середине (4.17 и 4.50): первый по SW и CH в общем пространстве, но восьмой по S_Dbw и AVU. Гауссова смесь M6 последняя в обеих постановках (6.00).

Средний ранг описывает таблицу и правилом выбора метода не служит. Сетевые индексы дают преимущество методам, которые работают на этой же сети (M7, M8), признаковые индексы дают преимущество KMeans в признаковом пространстве.

KMeans и Louvain напрямую, на одном графе декабря 2024: Louvain (итоговый запуск, K = 17) MQ 0.787, AVI 0.842, AVU 0.519; KMeans k = 6 MQ 0.608, AVI 0.774, AVU 0.593. Согласие разбиений: ARI 0.282 (по 100 запускам Louvain медиана 0.278, диапазон 0.229–0.317), взвешенная чистота 0.712; при равном числе

групп (resolution 0.25, K = 6) ARI 0.530, MQ 0.738, AVI 0.911. Сообщества Louvain в основном лежат внутри кластеров KMeans. Louvain по месяцам: среднее K 15.5, средний MQ 0.787; картина декабря типична для всего периода. Louvain не воспроизводится независимыми запусками: K от 14 до 19, ARI итогового запуска с остальными в медиане 0.678; границы и число сообществ нельзя читать как устойчивую структуру отдельных МО.

Отдельного текста «почему KMeans, а не Louvain» в репозитории нет; основания, которые можно вывести из отчётов шагов: центроиды KMeans читаются как профили долей, что нужно для интерпретации и сопоставления типов во времени при фиксированном k; запуски внутри месяца воспроизводятся (медианный ARI 0.966), а у Louvain число сообществ меняется от запуска к запуску; преимущество Louvain по MQ и AVI ожидаемо, так как он оптимизирует модулярность, и само по себе не означает лучшую типологию.

Индекс	Реализация	KMeans k = 6	Louvain K = 17
SW	sklearn.metrics.silhouette_score, евклидово пространство z-оценок	0.226	0.111
CH	calinski_harabasz_score; для сравнения k также CH/N = CH / N (N = 2 004)	763.9 (CH/N 0.381)	338.1
S_Dbw	Halkidi, Vazirgiannis (2001), пакет s-dbw; центр кластера: ближайшая к среднему точка; нормированный вариант относительно 100 случайных перестановок меток	1.182	0.598
MQ	модулярность Ньюмана (networkx), вес ребра равен сходству	0.608	0.787
AVI	Isolability = $2 \cdot E_{int} / (2 \cdot E_{int} + B)$, усреднённая по кластерам; формулы (18)–(21) в Shalileh, Antonov, Tsyplakova (2025)	0.774	0.842
AVU	Unifiability, усреднённая по K(K–1) парам кластеров, нормировка 1/K; значения от 0 до 1	0.593	0.519

Таблица 6. Шесть индексов: реализация и значения (декабрь 2024). Источнику: src/partition_metrics.py, notebooks/10_kmeans_k_selection.md, notebooks/11b_louvain_stability.md.

Индексы использованы как ограничение и не служили критерием выбора k среди $k \geq 4$. Ориентиры из публикации Shalileh et al. (2025), полученные на синтетических данных ($SW \geq 0.5$, $CH/N \geq 1$, $S_Dbw \leq 0.6$), при $k = 6$ не достигнуты (0.226, 0.381, 1.182); это согласуется с отсутствием выраженной кластерной структуры, но ориентиры применены только как справка. AVU почти не меняется при замене разбиения на случайное (0.600 у почти идеально разделённых клик против 0.598 у случайной разметки случайного графа, проверка на синтетике); разделённость читается по AVI и MQ. Индексы зависят от пространства: у M3 значения SW и CH в собственном и общем пространстве различаются заметно (0.246 и 0.184; 951.3 и 676.4). MQ, AVI и AVU считаются на графе, на котором работает Louvain, и дают ему преимущество.

6. Интерпретация и проверки

Типы проверены на связь с внешними показателями Росстата (население, зарплата и занятость, розничная торговля и общепит) и СберИндекса. Данные Росстата в построении типов не участвуют. Пороги проверок заданы до расчёта (нулевые распределения по перестановкам для уровней «общий» и «внутри регионов», хранятся с контрольными суммами); результаты разведочные и записаны как «отлично» или «не отлично» от случайного.

Размер МО (Г8): η^2_H 0.411 на общем уровне и 0.148 внутри регионов; самый сильный результат проверок.

Индекс доступности рынков (Г1): 0.393 и 0.045; порядок типов воспроизводится в 22 из 24 месяцев (правило не менее 23 не выполнено).

Г2: знак связи зависит от уровня сравнения (+0.494 между регионами, –0.301 внутри регионов, фигура 3).

Г7: учёт возраста не уменьшает различие по здоровью. Г9: не отлично. Г12 и Г13 внутри регионов не отличимы от случайного; Г10 меняет знак при замене показателя на число магазинов.

Контроль «региональный шум» (шаги 18 и 21): на общем уровне порог превышает в 0.925 и 1.0 повторов, внутри регионов не более чем в 0.04 повторов. Результаты общего уровня носят описательный характер. Определения гипотез и полные результаты: notebooks/26_hypothesis_summary.md.

Ограничения интерпретации. Пять категорий покрывают около 72% безналичных расходов. Привязка расходов к месту жительства или к месту покупки в описании набора не раскрыта, поэтому тип описывает структуру расходов в данных набора и может не совпадать с потреблением жителей. Интерпретационные имена описывают профиль типа и не оценивают МО; толкования, не следующие из пяти категорий (например, состав категории «Транспорт» или «Здоровье»), в данных не разложимы.

7. Лендинг и воспроизводимость

Результаты оформлены как один автономный HTML-файл (site/index.html, 4.8 МБ, без внешних ресурсов). Он содержит:

- интерактивную карту типов МО (2 594 полигона: 2 004 с типом выборки, 98 с типом по ближайшему центроиду, 74 с типом по последнему месяцу, 418 без типа) со слоями «Тип», «Доступность рынков», «Устойчивость типа»; слайдер по 24 месяцам; включение и выключение типа кликом по легенде; поиск МО; панель с данными МО; выгрузку типов по месяцам в CSV (2 004 строки, 27 колонок);
- шесть карточек типов, пять статических рисунков, таблицу проверок (46 строк, 213 чисел сверены с hypothesis_summary.parquet) и таблицу покрытия по регионам (85 строк).

Проверка: 138 контролей сборки; в браузере Chrome (три ширины окна, от 390 до 1440 px) проверены щелчок и выбор МО на семи контрольных МО, возврат цвета при фильтре по типу, отсутствие горизонтальной прокрутки, размер интерактивных элементов не менее 40 px на ширине 390 px. Не проверены: Safari, Firefox, жесты щипка и перетаскивания на сенсорном экране.

Код: 62 записи в run_all.sh (59 файлов кода в src/), параметры в config.yaml, зависимости в requirements.txt (15 пакетов с точными версиями; Python 3.13.5) и requirements-lock.txt.

Все случайные процедуры имеют фиксированные seed; при неожиданностях в данных скрипты останавливаются с сообщением STOP, а не исправляют данные.

Чистый прогон в копии проекта: 62 записи, все с кодом 0, 31 мин 40 с. Из 356 созданных файлов 343 совпали побайтно, 13 различаются: 7 таблиц parquet (последние разряды чисел, максимум $1.8e-12$) и 6 отчётов (строка со временем выполнения). Страница site/index.html собрана побайтно так же.

Исходные наборы данных (data/raw) в репозиторий не входят; источники, адреса и даты скачивания указаны в README.md. Справочник МО нужно положить в каталог ~/Documents/municipal_dict/ до запуска (инструкция в README.md).

Лицензии: код MIT; производные данные CC BY-SA 4.0 (авторство СберИндекса); данные Росстата CC BY 4.0. Сводка: DATA_LICENSES.md.